

DWTS 火热背后的数学奥秘

摘要

DWTS（与星共舞）是一款舞蹈比赛类真人秀，它以名人跟专业舞者搭档一起比赛的为特点受到很多人的关注。本文基于题目和节目提供的历史规则，基于有约束的规划算法设计出一款能解释赛题提问并且又能够很好的适用于其他相似规则的模拟投票器。本模型的优点在于误差小，准确性高；不足在于随机性低和随机森林多个特征容易过拟合，可以通过设置其他节目的规则函数和使用 LSTM 的方式推广模型。

对于问题一，根据从题目提供的数据中推断出规则分段函数，按题目要求列出排名法、百分比法、评委救场制的得分函数，综合成一个淘汰分段函数。以每周观众投票数为未知数，在时间平滑假设和总票数不变的约束下，构建出一个二次规划问题。通过反解规划问题，得到求出每周观众投票数的数学模型。通过已知每周最后排名反推出淘汰选手的方式，建立反向传播算法，将问题转化为拉格朗日问题，降低了求解难度。利用直接代入的验证方法得到正确率为 96.58% (254/263)。Kendall W 和 ICC 的随时间的波动区间为 0.70-0.95 和 0.65-0.90，说明了排名估计高度一致。通过变异系数 CV 和 95%的置信区间宽度 WCI 作为确定性指标。对于相同的选手和比赛周，它们的值并不固定，平均值分别为 0.0494 和 32095.78，说明对于观众投票数的估计有很大的确定性。

对于问题二，在已经求得的每季每周粉丝投票情况基础上，分别对于每一季采用四种方法，即只有排名法、只有百分比法、排名法加评委救场制、百分比法加评委救场制。通过热力图量化四种方法的有效性得知，百分制方法更偏向粉丝投票，能够放大粉丝投票优势；对于特定争议名人，百分制方法结合评委救场制超过 4.8 分，可显著改变争议选手命运，保护粉丝声音；纯排名方法 4.68 分，稳定最高，但易引发争议；只考虑百分数法 3.45 分，最容易受到粉丝投票影响。所以在未来建议使用百分数法结合评委救场制，是综合娱乐性和公平性的最好选择。

对于问题三，基于随机森林（具体）算法，建立起多元线性回归方程去分析年龄、行业和国别跟观众投票得分、评委打分得分和总得分之间的相关性。发现，年龄特征占 50%重要性总和的 40%，行业占 15%，国别占 5%-8%，其他包括舞者的不同占 10%左右。这些特征中年龄特征对观众投票得分和评委打分得分是最为重要，合计超过 35%。但是在行业特征中，评委打分得分更偏向于运动员/TV/媒体，重要性 0.03-0.04；而粉丝投票得分在歌手行业特征中，倾向性更强。

对于问题四，本文提出了一种三元得分+预表演+蒙面舞蹈周的趣味性和公平性兼具的规则，具体体现在将打分分为评委、在场观众和线上观众三方面，各自有不同权重。另外，在每周表演前一天，基于官方发布的练习片段、幕后花絮，开放一次预投票（仅限线上，

投票上限更低)。预投票不计入淘汰得分，仅用于节目播出时展示“预期人气排名”与实际表演后得分的对比；每季设置 1-2 周“蒙面周”，以褪去名人效应的影响。

关键词：二次规划；反向求解；拉格朗日问题；一致性；准确性；随机森林；

目录

一、背景.....3

二、基本假设.....4

三、术语与符号说明.....4

四、模型建立与求解.....4

 4.1.1 规则类型函数.....5

 4.1.2 淘汰决策函数.....6

 4.2 模型的求解（反向传播算法）.....8

 4.2.1 求解过程.....9

 4.2.3 观众投票数结果分析.....9

 4.4 问题二模型.....12

 4.4.1 各种规则的比较.....12

 4.4.2 结论.....13

 4.5 问题三模型.....15

 4.5.1 基于随机森林的特征重要性分析.....16

 4.5.2.各种特征的重要性分析.....16

 4.5.3 结论.....17

五、误差分析、灵敏度分析与模型评价.....18

5.1 误差分析.....	18
5.2 灵敏度分析.....	19
5.3 模型优缺点分析	20
六、模型推广	20
七、参考文献	21
八、附录.....	错误!未定义书签。
8.1 主要代码	错误!未定义书签。
8.2 主要数据表格.....	错误!未定义书签。
8.2.1 部分季节的一致性数据	错误!未定义书签。
8.2.2 部分数据的确定性数据	错误!未定义书签。
8.2.3 部分数据的投票数.....	错误!未定义书签。
8.2.4 部分数据的随机森林重要性数据.....	错误!未定义书签。
九.AI 使用记录.....	错误!未定义书签。

一、背景

随着人们生活水平的提高，有趣又积极的电视节目层次不穷。《与星共舞》（DWTS）是美国 ABC 电视台推出的比赛类真人秀节目，不同的舞者搭档会选择自己风格的舞蹈，这些舞者搭档是来自社会各界的名人，他们通过观众和评委共同选择出最后决赛的获胜者。

随着节目一年又一年的举办，也发现了一些规则上的问题。比如名人选手 BobbyBones 尽管评审分数持续低迷却赢得了冠军。为了追求更公平的比赛结果节目尝试过排名法，百分比法，还有加上评委救场制的综合方法，以均衡人气超多或者人气低迷的影响。本文尝试去分析这些不同的方法和舞者搭档的特征对于投票数和获胜情况的影响，并试图提出更公平，更好的打分规则。本文主要完成以下任务：

问题一，投票模拟器的建立与粉丝投票数求解。

问题二，分析投票模拟器预测的粉丝投票数的一致性和确定性。

问题三，不同投票评价方法的比较和分析。

问题四，舞者特征聚类模型的建立及更好的投票评价方法。


二、基本假设

- 1. 假设 28 季的时候第一次评委救场制，从第 1 到 2 季和 32 季采用排名法，第 3 到 27 季采用百分比法，第 28 到第 31 采用的是百分比法和评委救场制，第 33 到第 34 采用的是排名法和评委救场制。
- 2. 假设评委的投票是专业的，且不受个人情感所左右的。
- 3 假设每次总的投票数是一千万，而且每一次的淘汰周的观众投票数是不变的。无淘汰周的投票不影响淘汰周的投票。
- 4. 假设观众的投票数是保密的，不能够事先知道。

三、术语与符号说明

符号	定义
$\hat{v}_{i,w}$	第 w 周的选手人数
N_w	选手 i 在第 w 周的估计票数
$T.$	常量,每周的总票数约束
$\bar{v}_i$	变量,选手 i 的基准投票数
$R_{i,w}^J$	选手 i 在第 w 周的评委排名
$R_{i,w}^V$	选手 i 在第 w 周的投票排名
$J_{i,w}$	选手 i 在第 w 周的评委分数
J_{save}	评委救场函数
$P_{i,w}$	选手 i 在第 w 周的投票百分比
$A(i,w)$	选手 i 在第 w 周是否晋级
$D(i,w)$	淘汰决策函数 (1=淘汰, 0=晋级)
E_w	第 w 周被淘汰的选手集合
λ	平滑性约束的权重参数
BottomTwo _w	第 w 周进入救场环节的底部两名选手
ϵ	淘汰约束中的最小差距阈值
$\alpha_0,\alpha_1,\alpha_2,\beta$	基准投票数模型的回归系数

四、模型建立与求解



4.1 投票模拟器模型

基于历史数据分析，我们将淘汰机制建模为一个关于赛季 s 的分段函数。该函数决定了综合得分的计算方式以及最终的淘汰决策逻辑函数 $D(i, w)$ 。

4.1.1 规则类型函数

通过对于题目给的表格进行分析，发现节目的运行规则如下，

赛季区间	评委救人权 (Judges' Save)	核心算法依据
S1 - S27	无	排名法 (S1-2) / 百分比法 (S3-27)
S28 - S31	有	百分比法 + 评委救人
S32	无 (取消)	排名积分法 + 直接淘汰
S33 - S34	有 (回归)	排名积分法 + 评委救人 (最平衡模式)

通过 wiki 百科关于 DWTS 的词条，知道在第 32 季，节目组做出了一个大胆的决定：完全移除“评委救人权 (Judges' Save)”。为什么第 32 季取消了救人权呢？根据制作人 Conrad Green 在 Entertainment Weekly 等媒体的访谈，取消的原因主要有两点：回归线性频道 (ABC)：第 32 季是节目从 Disney 重新回到 ABC 电视台同步直播的一季，制作组希望规则更透明、更传统。

增加了紧迫感，去掉评委的“保护伞”，让比赛变得更加不可预测，每一票都变得生死攸关。然而，第 32 季结束后，观众发现没有评委救人会导致一些优秀的舞者因一次投票低迷而意外出局。到了第 33 季，节目组听取了反馈，重新引入了“评委救人权”。目前最

新的第 34 季依然保留了这一权力，形成了“排名积分决定底两名 + 评委二选一”的最终稳定模式。【1】

除了有关评委救场制的规则在变动之外，DWTS 每一季都会有不同的玩法，比如有‘一起跳老歌’、‘斗舞’等增加节目趣味性的方式，这些方式不一定会淘汰选手，所以有了一周有两晚的现象。但是让一些比赛周不淘汰人的话，如果不改变原来的淘汰方式，就不能在规定的时间内播完节目。多人淘汰制，最多能淘汰 3 人。

基于上述结合题目和 DWTS 节目的了解，有下面的规则分段函数，

$$R(s, w) = \begin{cases} \text{rank}, & (s \in [1, 2] \cup \{32\}) \wedge (w \notin W_{\text{noelim}}(s)) \\ \text{percent}, & (s \in [3, 27]) \wedge (w \notin W_{\text{noelim}}(s)) \\ \text{percent} + \text{save}, & (s \in [28, 31]) \wedge (w \notin W_{\text{noelim}}(s)) \\ \text{rank} + \text{save}, & (s \in [33, 34]) \wedge (w \notin W_{\text{noelim}}(s)) \\ \text{no-elimination}, & w \in W_{\text{noelim}}(s) \end{cases} \quad (1.1)$$

这里 $W_{\text{noelim}}(s)$ 是指无淘汰周。

4.1.2 淘汰决策函数

在了解淘汰决策函数之前，先介绍指示函数（Indicator Function），定义如下：

设 A 是一个集合（或事件），则指示函数通常记为 $I_A(x)$ ，其中 x 是一个元素。

$$I_A(x) = \begin{cases} 1 & \text{当 } x \text{ 属于 } A \\ 0 & \text{当 } x \text{ 不属于 } A \end{cases} \quad (1.2)$$

也就是说，如果元素 x 属于集合 A （或事件 A 发生），则 $I_A(x) = 1$ ；否则 $I_A(x) = 0$ 。

对于不同的时间节点使用不同的晋级函数 $A(i, w)$ ，而不同的晋级函数又有不同的约束条件，如下面几个阶段。

情况 1：排名法，正如题目中所说的那样，将评委分数排名和粉丝投票数排名相加得到总的排名数。组合排名最高的选手被淘汰。晋级函数表达式如下，

$$A(i, w) = 1 - I\left((R_{i,w}^J + R_{i,w}^V) = \max_{k \in C_w} (R_{k,w}^J + R_{k,w}^V)\right) \quad (1.3)$$

评委排名和观众投票数排名，分别为：

$$R_{i,w}^J = \text{rank}(S_{i,w}, \{S_{k,w} : R = 1, \dots, N_w\}) \quad (1.4)$$

$$R_{i,w}^V = \text{rank}(v_{i,w}, \{v_{k,w} : I_k = 1, \dots, N_w\})$$

而 $\text{rank}(x)$ 表示在所有选手中按分数降序排名（最高分=1，最低分= N_w ）。又因为总票数为 T ，然后被淘汰选手的组合排名必须大于等于未淘汰选手。

故，约束条件如下，

$$\sum_{i=1}^{N_w} v_{i,w} = T \quad v_{i,w} \geq 0 \quad R_{i,w}^J + R_{i,w}^V > R_{j,w}^J + R_{j,w}^V \quad \forall i \in E_w, j \notin E_w \quad (1.5)$$

情况 2：百分比法，正如题目所说的那样，将评委打分的百分比和粉丝投票的百分比相加得到总的百分比数。组合排名最低的选手被淘汰。晋级函数表达式如下，

$$A(i, w) = 1 - I\left(P_{i,w} = \min_{k \in C_w} P_{k,w}\right) \quad (1.6)$$

$P_{i,w}$ 是组合百分比等于 $\frac{S_{i,w}}{\sum S} + \frac{v_{i,w}}{T}$ ，即评委百分数比加上观众百分数比。所以，

$$P_{i,w} = \frac{S_{i,w}}{\sum S} + \frac{v_{i,w}}{T} \quad (1.7)$$

被淘汰选手 j 满足：

$$P_{j,w} = \min_{k \in C_w} P_{k,w} \quad (1.8)$$

因为百分比的总数是常数 T ，而且评委分数百分比和观众投票百分比相加，总和最低的选手被淘汰，所以有如下约束：

$$\sum_{i=1}^{N_w} v_{i,w} = T \quad v_{i,w} \geq 0 \quad P_{j,w} \leq P_{k,w} \quad \forall j \in E_w, k \notin E_w \quad (1.9)$$

情况 3：评委救场规则

1. 对于排名法的最后两名，有

$$\text{BottomTwo}_w = \{i \in C_w : (R_{i,w}^J + R_{i,w}^V) \in \{\text{Maximum and second maximum}\}\} \quad (1.10)$$

$$A(i, w) = \begin{cases} 0, & i \in E_w \cap \text{BottomTwo}_w \\ 1, & \text{else} \end{cases}$$

2. 对于百分比法的最后两名，有

$$\text{BottomTwo}_w = \{i \in C_w : P_{i,w} \in \{\text{Minimum and second minimum}\}\} \quad (1.11)$$

$$A(i, w) = \begin{cases} 0, & i \in E_w \cap \text{BottomTwo}_w \\ 1, & \text{else} \end{cases}$$

这里的 C_w 指的是第 w 周仍在比赛中的选手集合。

结合这三种情况，有淘汰函数，为：

$$D(i, w) = \begin{cases} 0 & w \in W_{\text{noelim}}(s) \\ I\left((R_{i,w}^J + R_{i,w}^V) = \max_{k \in C_w} (R_{k,w}^J + R_{k,w}^V)\right), & \text{Ranking-based method} \\ I\left(P_{i,w} = \min_{k \in C_w} P_{k,w}\right), & \text{Percentage-based method} \\ I(i \in \text{BottomTwo}_w \wedge J_{\text{save}}(i) = \text{out}), & \text{Judge save system} \end{cases} \quad (1.12)$$

这里的 $J_{\text{save}}(i)$ 指的是评委救场决策函数。

4.2 模型的求解（反向传播算法）

本赛题提供的数据包括每周的评委打分情况、选手最后的得分情况，但是缺少观众投票数。

假设每周观众投票数不变，且每周观众投票数为一千万。

4.2.1 目标函数

$$\min \sum_{s=1}^{34} \sum_{w=1}^{W_s} \left[\alpha \cdot D(\mathbf{v}_{s,w} \parallel \mathbf{v}_{s,w}^{\text{indge}}) + \beta \cdot D(\mathbf{v}_{s,w} \parallel \mathbf{v}_{s,w}^{\text{next}}) \right] \quad (1.13)$$

通过反向传播算法，可以等价于：

$$\min_{\langle \Psi_{s,w} \rangle} \sum_{s=1}^{34} \sum_{w=1}^{W_s} \left[\alpha \cdot D_{\text{KL}}(p_{s,w} \parallel \mathbf{P}_{s,w}^{\text{judge}}) + \beta \cdot D_{\text{KL}}(\mathbf{P}_{s,w} \parallel \mathbf{P}_{s,w}^{\text{next}}) \right] \quad (1.14)$$

Kullback-Leibler 散度用于度量两个概率分布之间的差异，定义为：

$$D_{\text{KL}}(\mathbf{p} \parallel \mathbf{q}) = \sum_i p_i \log \frac{p_i}{q_i} \quad (1.15)$$

其中，各个矩阵如下：

$$\mathbf{P}_{s,w}^{\text{next}} = \frac{\mathbf{v}_{s,:,w+1}}{\|\mathbf{v}_{s,:,w+1}\|_1} \quad (1.16) \quad \mathbf{P}_{s,w}^{\text{judge}} \equiv \frac{\mathbf{S}_{s,:,w}}{\|\mathbf{S}_{s,:,w}\|_1} \quad (1.17) \quad \mathbf{P}_{s,w} = \frac{\mathbf{P}_{s,w}}{T} \quad (1.18)$$

4.2.1 求解过程

初始化：从最后一周 $w=W_s$ 开始，利用最终排名信息，得到 $v_{i,s,w} = \alpha v_{i,s,w}^{\text{indge}} + \beta v_{i,s,w}^{\text{next}}$ ，

$$w_{i,s} = w_{i,s}^{\text{rank}} + w_{i,s}^{\text{judge}}, \text{ 其中, } v_{i,s,w}^{\text{judge}} = T \cdot \frac{S_{i,s,w}}{\sum_{j \in C_{s,w}} S_{j,s,w}}, \quad v_{i,s,w}^{\text{next}} = T \cdot \frac{v_{i,s,w+1}}{\sum_{j \in C_{s,w}} v_{j,w+1}},$$

$$w_{i,s}^{\text{judge}} = \frac{S_{i,s,W_s}}{\sum_{j \in C_{s,W_s}} S_{j,s,W_s}}.$$


传播：依次向前一周传播， $w = W_s - 1, W_s - 2, \dots, 1$

平滑：利用时间连续性约束保证估计的平滑性， $\mathbb{R}[v_{i,s,w} | v_{i,s,w+1}] \approx v_{i,s,w+1}$ 模型隐含了时间平滑性的假设。除了归一化约束还有：

$$\sum_{j \in C_{s,W_s}} S_{j,s,W_s} = 0 \quad \alpha, \beta > 0$$

4.2.3 观众投票数结果分析

对下图进行分析，通过已结合公开的《Dancing with the Stars》(DWTS) 历史记录（通过网络搜索验证，包括 Wikipedia、官方 wiki、EW、People、Cosmopolitan 等来源）进行交叉验证【2】。验证了上面的数据，发现准确率高达 96.58% (254/263)。从图像上可以看出，图表完全一致于第 34 季真实结果。模型准确反映了，冠军 Robert Irwin 的“爆炸式粉丝增长，早期低支持率选手（如 Corey Feldman）的快速出局，无明显“shock elimination”（高票却淘汰），说明第 34 季规则下投票主导性强。



4.2.3.1. 一致性分析

一致性是指模型预测结果与真实值的协同程度与可靠性。本文采用组内相关系数 (ICC) 和肯德尔和谐系数 (Kendall W) 作为一致性指标。

肯德尔和谐系数 (Kendall W) 定义如下：


$$W = \frac{12S}{m^2(n^3 - n)}$$

S: 秩和的平方和, m: 评分者 (方法) 数量, n: 被评价对象 (样本) 数量, 取值范围: [0, 1], 1 表示完全一致, 0 表示无一致性。Kendall W 值在本文用于衡量排名选手方面的一致性, 值越大表明不同方法对选手的优劣排序具有共识。

2. 组内相关系数 (ICC) 定义如下:

$$ICC = \frac{MS_R - MS_E}{MS_R + (k-1)MS_E + k(MS_C - MS_E) / n}$$

MSR: 被试间均方 (选手间的方差) MSC: 评分者间均方 (方法间的方差) MSE: 误差均方
组内相关系数 (ICC) 在本文中的作用为评估不同估计方法测量同一选手投票数的可靠性。高 ICC 值表明不同方法对同一选手的估计结果高度一致, 模型具有很好的信度。



分析图表, ICC (蓝色折线) 趋势:

整体波动区间: 0.70-0.95; 1-10 季, 波动较大, 平均 0.75; 11-24 季, 逐渐稳定, 平均 0.85; 后面 25-34 季: 维持在 0.85 以上, 第 25 季达到峰值 0.95。

Kendall W (橙色折线) 趋势:

整体波动区间: 0.65-0.90, 波动幅度小于 ICC, 整体呈缓慢上升趋势, 最高点出现在第 30 季 0.90。

可以得知 ICC 和 Kendall W 均保持较高水平, 说明: 模型成熟, 估计方法经过优化达到稳定状态; 规则稳定, 比赛规则趋于统一

根据 Cicchetti(1994)的标准【3】: 模型在 34 个赛季中, 28 个赛季 ICC>0.75, 达到优秀标准。

根据 Landis 和 Koch(1977)的标准【4】, 后期季节 Kendall W 稳定在 0.8 以上, 表明排名估计高度一致。

4.3.2.2 确定性检测：

确定性是指模型输出结果的把握程度及对随机干扰的抵抗力。本文对投票数据的确定性可以通过变异系数和置信区间宽度来表示，CV 反应了数据的稳定性，CV 的值越小越稳定，也越确定；WCI 反应了数据估计的精度，它的宽度越大估计的不确定性就越大。

CV（变异系数，Coefficient of Variation），定义如下：

$$CV = \frac{\sigma}{\mu}$$


其中 σ 是估计值的标准差， μ 是估计值的均值。CV 是标准化的波动度量，消除了量纲影响。当 CV 较低时，说明估计值围绕均值的相对波动小，估计确定性高。

WCI（置信区间宽度，Width of Confidence Interval），定义如下：

以均值估计 95% 的置信区间为例，


$$WCI = 2 \times z_{0.975} \times \frac{\sigma}{\sqrt{n}}$$

其中 $z_{0.975} \approx 1.96$ 是标准正态分布的分位数，是标准差， n 是样本量。WCI 反映了估计的精度。宽度越大，表示估计的不确定性越大。WCI 受样本变异（ σ ）和样本量（ n ）影响。



稳定性（CV）极佳，是确定性的基石：均值极低，平均 CV 仅为 0.0494，意味着估计值围绕其均值的平均波动只有约 4.94%。这远低于常规认为“良好”的阈值（如 0.1）。CV 分布集中，CV 中位数更是低至 0.007（0.7%），说明超过一半的估计结果，其波动性微乎其微。柱状图也显示绝大部分 CV 值堆积在 0 附近；“周次平均 CV 趋势”图显示，各周次的平均 CV 始终远低于 0.1 的“极高确定性”阈值线，且没有明显的上升或恶化趋势，过程控制良好；99.03% 的估计被划分为“极高确定性”。

精度（WCI）处于常规可接受范围：平均 WCI 为 32095.78，每周投票数为 10million，精度大约为 0.003209578。而且，箱线图显示其分布是“正常”的波动，没有系统性偏移的迹象。下面结合具体的例子分析，



VD（可行域，Feasible Domain）通常指在约束优化问题中，所有满足约束条件的解构成的集合。VD 缩小表示约束更紧、可行解空间更小，可能使优化问题更难，估计更易受边界影响。

发现，随着比赛（周次）的进行：不确定性持续增加，WCI（置信区间宽度）从第1周的约5万，单调上升至第10周的约12万。这意味着，模型对粉丝投票数的估计精度在持续、显著地下降。我们越来越不确定“真实票数”到底在哪。；稳定性剧烈波动，CV（变异系数）在0.0165到0.0195之间高位震荡，没有改善趋势。说明估计值本身的波动性很大，可重复性差；约束收紧无效：尽管可行域在不断收紧（vd. 大→vd. 小→vd. 极小），但并未能阻止WCI的上升和CV的波动。这指明，问题的根源不在于搜索空间太大，而在于模型或数据的根本假设与实际情况出现了越来越大的偏差。


这揭示了在后期，选手变少同样的票会产生绝对偏差，会被剧烈地放大；还说明，后期竞争越来越白热化，结果变得越来越敏感，这恰恰是节目追求的效果。

4.4 问题二模型

4.4.1 各种规则的比较

问题二旨在分析出不同淘汰方法的特点，以及它们对于比赛结果的影响，对于一些有很大粉丝号召力的人尤其关注。


本文采取控制变量的形式进行分析，在问题一所求的粉丝投票数的基础上，只考虑单一的淘汰模式，发现，比例制直接使用票数比例，更忠实地反映观众偏好，与评委分更一致。排名制通过“排名”压缩票数极端值，削弱了观众票的直接影响力，更容易出现“评委低分但粉丝多”的选手存活困难，争议更大。救场规则在比例制下进一步提升一致性（救下评委认可但票少的人）；在排名制下反而略微降低（救场有时违背排名逻辑）。



分析得，用热力图证明百分比法更偏粉丝（争议选手受益、但稳定性差），排名法更平衡稳定。推荐排名法加评委救场制（因为热力图整体绿色最多，稳定性高、竞争激烈），这样显得更公平专业、减少粉丝极端主导、比赛更长悬念。如果节目想放大娱乐性，可用百分比法（对争议选手保护好，相关性高）。最后，本文强烈建议加评委救场制右下图显示它能大幅提升争议选手排名，平衡分歧。揭示了，排名制带来更激烈、更稳定的竞争，但会降低评委与观众的一致性（更容易产生争议）；比例制更能反映观众偏好、结果更一致，但竞争较弱、波动较大。评委救场制在两种计分制下都起到“缓冲”作用，能同时提升一致性和稳定性。

4.4.2 结论


4.4.2.1. 评委分数与观众投票的关系



如图所示，整体样本中平均评委分数与观众投票量的 Pearson 相关系数为 0.568，呈现中等正相关，表明专业评价与大众审美在大多数情况下趋于一致。然而，在高分段（评委分数 8-10 分），观众投票呈现显著离散性，票数范围从不足 100 万至超过 400 万不等。这表明在顶尖选手竞争阶段，舞蹈技术的边际改进效应递减，粉丝基数成为决定性因素。

进一步按赛季分析，早期赛季（1-15）相关系数普遍高于 0.6，后期部分赛季降至 0.3 以下（橙色柱状），反映社交媒体时代粉丝投票独立性增强。


4.4.2.2. 两种计分方法的比较



我们对所有赛季分别应用百分比法和排名法两种方法进行全流程模拟。竞争长度与强度：排名法方法下平均竞争周数更长（左下图蓝线波动大），剩余选手数更多（左上图），表明其淘汰节奏更缓慢、更依赖技术积累。稳定性：排名制加评委救场制的排名波动指数最低（右下图红柱），竞争最稳定。对粉丝投票的偏向：百分比法在粉丝支持强烈的赛季中，争议选手最终排名平均提升 2.1 名，显著高于排名法（提升 0.8 名）。这因为百分比法直接使用票数比例，放大粉丝基数优势，而排名法通过排名压缩极端值，更平衡评委权重。

实证结果表明，百分比法方法更偏向粉丝投票，尤其在后期赛季表现明显。

4.4.2.3 争议选手案例分析



针对典型“评委-粉丝分歧”选手进行专项模拟，Jerry Rice（第 2 季）：在三种机制下均表现出色，最终排名稳定在前 2 位。其中，百分比制和百分比制+救场机制下接近冠军，排名加和制下略降至第 2 位，反映其兼具较强的评委认可与粉丝支持。Billy Ray Cyrus（第 4 季）：尽管有 6 周评委垫底，在百分比制+救场机制下排名显著提升至前 2 位，百分比制下约为第 3 位，而排名制下跌至第 7 位左右，表明百分比制结合评委救场制能有效保护粉丝型选手。Bristol Palin（第 11 季）：12 次评委最低分的情况下，百分比制+救场机制下稳居前 2 位，纯百分比比例制下约为第 4 位，排名制下则跌至第 6 位，凸显救场规则对评委-粉丝分歧选手的关键保护作用。Bobby Bones（第 27 季）：持续低评

委分却在百分比制+救场机制下夺冠（第 1 位），纯百分比制下约为第 3 位，排名制下仅为第 5 位，典型体现了百分比制放大粉丝优势、救场进一步强化其生存能力的机制特征。

结果显示，计分方法选择直接影响结局：百分比法结合评委救场制可显著改变争议选手命运，保护粉丝声音；纯排名方法则更倾向“技术优先”，易引发争议。


4.4.2.4 规则组合综合评估

通过热力图量化四种政策组合的有效性（综合得分考虑稳定性、相关性、竞争长度、争议度）：排名法加评委救场制：平均得分 4.68，稳定性最佳，但争议最高，只有百分比法：平均得分 3.45，竞争最动态，但易产生“粉丝冠军”，百分比法加救场制：后期赛季得分最高（>4.8），综合最优。

4.5 问题三模型

为量化职业舞者（Pro Dancers）及名人特征（年龄、行业、国家等）对比赛表现的影响，我们构建了随机森林回归模型，分别预测平均评委分数（avg_judge_score）、观众投票量（fan_votes）及最终排名（final_placement）。模型通过特征重要性分析揭示各因素的影响程度，并结合散点图、分布图等可视化结果进行解释

经过统计得，有如下年龄，行业，国家有如下分布：



参赛者年龄分布如图 2 所示，均值 38.8 岁，中位数 36 岁，呈右偏态，峰值集中在 30-40 岁区间，表明节目偏好青壮年选手。高龄（>60 岁）参赛者极少，反映生理门槛限制。

国家/地区分布如图 1 所示，美国选手占比高达 96.3%（365 人），其他国家（如英格兰 11 人、加拿大 9 人）占比极低，显示节目强烈的本土化特征。行业分布如图 3 所示，演员/女演员占比最高（30.4%），其次为运动员（23.0%）、TV/媒体名人（15.9%）及歌手/音乐人（14.7%）。这一分布反映节目选秀策略：优先选择具备表演基础或粉丝动员能力的行业背景。

4.5.1 基于随机森林的特征重要性分析

随机森林（Random Forest）【5】是一种集成学习算法，通过构建多棵决策树并聚合预测结果，能够有效捕捉特征与目标变量间的非线性关系。特征重要性采用基于均方误差（MSE）减少量的指标计算。对于特征 j ，其重要性定义为

$$I_j = \sum_{t \in T} \sum_{n \in N_t} w_n \cdot \Delta \text{MSE}(n), f_n = j$$


其中， T 为森林中所有决策树； N_t 为第 t 棵树的所有节点； $f_n = j$ 表示节点 n 使用特征 j 分裂； w_n 为节点样本权重； $\Delta \text{MSE}(n)$ 为分裂前后均方误差减少量。

为捕捉非线性影响（生理机能随年龄先升后降），设因变量 Y ，连续值年龄 x ，对于（评委/观众投票/参赛者表现）得分模型有如下方程：

$$Y = \beta_0 + \beta_1 x + \beta_2 x^2 + \sum_{k=1}^5 \gamma_k D_k + \lambda_i C_i + \varepsilon$$

其中 D_k 为行业哑变量（其作用是让这批数据都在同一个行业内） C_i 为国家哑变量， $\varepsilon \sim N(0, \sigma^2)$ ， $\alpha, \alpha_1, \beta, \beta_1$ 和 θ, λ 为参数。


4.5.2.各种特征的重要性分析



- (1) 对最终排名的影响（如图 1），年龄相关特征（age 与 age_squared）重要性合计超过 0.40，位列前二，实证证实生理机能是决定最终排名的核心因素。行业背景中，TV/媒体（约 0.04）与运动员（约 0.03）重要性突出，前者利于粉丝动员，后者利于技术得分。职业舞者特征（如 pro_Derek Hough）重要性约 0.02-0.03，印证其隐性加分效应。
- (2) 对评委分数的影响（如图 2），年龄及二次项同样主导（合计>0.35），反映评委更注重生理协调性。行业效应中，TV/媒体与模特背景重要性较高（约 0.03-0.04），可能因表演经验更易获得专业认可。部分职业舞者（如 pro_Derek Hough）重要性显著，表明其教学能力直接提升技术得分。

(3) 对观众投票的影响（如图 3），年龄因素仍最重要（合计 >0.35 ），年轻选手更易获得粉丝共鸣。歌手/音乐人行业重要性最高（约 0.08），其次为 TV/媒体，反映音乐与媒体曝光带来的粉丝基数优势。职业舞者影响相对较小（ <0.03 ），表明粉丝投票更依赖名人自身魅力而非舞伴。

(4) 评委分数与观众投票的关系



散点图显示整体正相关（趋势线斜率为正），但高分段（8-9 分）粉丝票波动剧烈（从 <100 万至 >400 万），说明顶尖选手竞争中，技术提升的边际效应递减，粉丝基数成为胜负关键。

Judge Model R	Fan Model R	Joint Model R
0.2435	0.2206	-0.9854

4.5.3 结论

问题 1. 这些因素（年龄、行业、国别）在多大程度上影响一位名人在比赛中的表现？年龄因素占 50%重要性总和的 40%，行业占 15%，国别占 5%-8%，其他包括舞者的不同占 10%左右。其中对于评委和粉丝，重要性都超过了 35%，行业中评委更偏向专业技能的选手，而粉丝更多受个人魅力所影响。

问题 2. 它们对评委打分和粉丝投票的影响方式是否相同？100.0% 的特征对评委得分和最终排名的影响方向一致。年龄对于两者的影响是相似的，年龄主导两者（重要性合计 >0.35 ），相同倒 U 型（age_squared 负系数显著），但是行业特征不同，评委偏好运动员/TV/媒体（重要性 0.03-0.04，歌手系数对粉丝-5.7 强过评委-5.5）。

4.4 问题四模型

为了降低名人效应对于粉丝的影响和让比赛机制更加稳定和牢固，本文提出一种全新的投票系统，“三元平衡投票系统”（Triple-Balanced Voting System），旨在提升公平性（更尊重技术表现）、减少争议，同时显著增加节目的刺激性和叙事张力。

具体内容如下：

系统核心规则（每周执行），使用评委的打分+线下观众打分+线上观众打分且不同权重的方式，沿用现有评委打分（满分 30 或 40 分制），转化为百分比（该选手总分 / 所有选手总分之和）。这部分强调舞蹈技术、编排、执行力。线上粉丝投票（35%权重），表演

结束后开放线上投票（保留现有投票上限），转化为百分比。这部分保留粉丝对名人魅力、故事线的热情。现场观众即时投票（15%权重），每位现场观众通过手机 App 或投票器，在每对选手表演结束后立即投票（简单“最喜爱”单选）。现场投票总量转化为百分比。这部分捕捉现场真实能量与即时反应，避免线上投票受预剪辑、宣传、名人光环的过度影响。

辅助刺激机制：预表演“人气热力投票”（Pre-Show Buzz Vote）在每周表演前一天，基于官方发布的练习片段、幕后花絮，开放一次预投票（仅限线上，投票上限更低）。预投票不计入淘汰得分，仅用于节目播出时展示“预期人气排名”与实际表演后得分的对比。额外奖励：如果某选手实际最终得分显著高于其预投票预期排名（例如提升 3 位以上），给予小额 bonus 分数（+2%最终得分），奖励“进步最大”或“超预期表现”。

特殊周：蒙面舞蹈周（Masked Dance Week）每季设置 1-2 周“蒙面周”：选手表演时降低灯光、戴简易面具或使用剪影效果，隐藏面部特征，仅展示身体与舞蹈。该周现场观众与线上粉丝投票强制基于纯舞蹈表现（节目可强调“盲评”规则）。目的：暂时削弱名人光环，让投票更贴近技术，提升公平性，同时制造“猜身份”的悬念，极大增强观赏乐趣。除了更多层次的投票方式，蒙面也极大增加了节目的买点，也已经有过成功案例，中国综艺节目《蒙面歌王》【6】。

五、误差分析、灵敏度分析与模型评价


5.1 误差分析

使用相对误差（MRE）作为误差量化标准， $\bar{v}_{i,w}$ 为预期投票数， $v_{i,w}^{\text{true}}$ 为真实投票数

$$\text{MRE} = \frac{1}{n} \sum_{i,w} \left| \frac{\hat{v}_{i,w} - v_{i,w}^{\text{true}}}{v_{i,w}^{\text{true}}} \right|$$

模型的主要误差来源于以下几个方面：模型假设偏差假设每周总票数固定为常量

$T=10^7$ ，而实际观众投票总量可能随赛季热度、周次、社交媒体传播等因素波动，假设投票数在时间上平滑（通过平滑约束 λ 惩罚剧烈变化），但真实粉丝投票可能存在突发事件（如争议性表演、外部新闻）导致的跳变；评委救场函数 J_{save} 采用简化决策（假设评委始终救下技术更优者），忽略了评委主观偏好或节目剧本需求；数据与规则简化误差部分赛季存在“无淘汰周”或“多人同时淘汰”，模型通过指示函数处理，但无法完全捕捉特殊玩法（如斗舞周）的细微影响。数据中缺失部分历史投票记录，完全依赖反推，可能放大早期周次的误差并向后传播；反向传播算法将原约束优化问题转化为最小化 KL 散度形式（式 1.14-1.18），但在数值求解时引入了松弛阈值 ε ，导致在边界附近可能产生微小排名错误。




如图，展示了模型估计的粉丝投票数的周际稳定性。左子图显示，绝对周际变化率主要集中在 0-0.15 区间，表明绝大多数选手每周投票数变化平缓，佐证了时间平滑约束的有效性。右子图进一步揭示，各赛季变化率中位数接近零，四分位距较小，即使在规则频繁调整的后期赛季（25-34），整体波动仍保持可控。该结果与变异系数 CV 平均仅为 0.01789 高度一致，共同证明了模型估计的高确定性和低误差特性。

5.2 灵敏度分析

灵敏度分析考察模型输出【7】（估计投票数 $\bar{v}_{i,w}$ 、淘汰准确率、一致性指标）对关键参数扰动的响应。

$$S_{\theta} = \frac{\partial O}{\partial \theta} \approx \frac{O(\theta + \Delta\theta) - O(\theta - \Delta\theta)}{2\Delta\theta}$$

数学上采用局部灵敏度指标，其中 O 为目标输出（如准确率或平均 CV）， θ 为待分析参数；平滑权重 λ ，控制时间平滑性；总票数约束 T ，淘汰阈值 ε ，救场决策偏差（引入随机扰动）。



对平滑权重 λ 的灵敏度，当 λ 从 0.1 变化到 10（ $\pm 90\%$ 扰动）时，准确率波动范围为 95.8% ~ 97.2%（最大下降 0.78%），平均 CV 从 0.0494 上升至 0.063（相对增加 27.5%）；对总票数 T 的灵敏度，将 T 在 $[8 \times 10^6, 12 \times 10^6]$ 区间扰动（ $\pm 20\%$ ），投票数估计值线性缩放（因归一化约束），但排名顺序几乎不变，准确率波动 < 0.5%，说明模型对绝对票数规模不敏感，仅依赖相对比例对阈值 ε 的灵敏度， ε 0.001 变化到

0.1, $\varepsilon > 0.5$ 时, 可行域急剧扩大, 导致多个赛季出现“排名并列”无法区分, 准确率下降至 92.3%。

综合结论: 模型整体鲁棒性强, 参数扰动 $\pm 20\%$ 时准确率波动 $<1\%$, 排名波动 $<5\%$ 。最敏感参数为 ε 和救场决策逻辑。

5.3 模型优缺点分析

优点: 确定性高且一致性强, 在特定规则的情况下, 比较稳定。粉丝投票估算模型通过线性回归模型实现了与实际淘汰结果的高度一致, 随机森林模型的特征重要性指标 (MSE 减少量) 准确捕捉了年龄 (重要性 >0.35) 与行业背景的非线性影响, R^2 分数达 0.72-0.78, 显著优于基准线性模型。显著优于基准线性模型。鲁棒性, 一致性指标较高, 引入二次项 (Age) 与行业/国家, 增强了模型对非线性关系的捕捉, 灵敏度分析显示阈值变化 $\pm 10\%$ 时排名波动 $<5\%$, 证明模型对参数扰动鲁棒。解释性强, 随机森林提供了可解释的特征重要性 (如年龄主导评委分, 行业主导粉丝票), 结合散点图与分布图, 直观揭示影响机制, 便于决策应用。

缺点: 过拟合风险, 随机森林虽使用集成方法, 但特征过多可能导致过拟合, 交叉验证 R^2 虽高, 但泛化到新赛季需进一步测试。

模型缺少随机性和更普遍的泛化性, 本文模型的每周投票数和规则是固定的所以能变成相对‘静止’的规划问题求解, 但是实际情况是投票数是会不断变化的, 而规则又是节目方每一集有会有所调整。

六、模型推广

跨节目推广模型对投票规则的抽象化处理 (排名法、百分比法、救场制等分段函数) 使其易于迁移至类似节目。例如: 《美国偶像》(American Idol) 与《The Voice》: 这些节目同样采用观众投票与评委/导师意见结合的机制。可直接复用反向传播算法估算隐藏的观众投票数, 仅需调整权重参数 (例如导师“转椅”或“救人”相当于救场制)。预计在规则相对稳定的赛季中, 淘汰预测准确率可达 95% 以上。英国版《Strictly Come Dancing》及中国综艺, 如《歌手》, 这些节目常引入“复活赛”“导师加分”等变体。通过扩展淘汰约束函数 (增加指示变量), 模型即可适应, 量化不同规则对“技术流”与“人气流”选手的偏向。

未来赛季预测与规则优化支持, 利用已估算的 34 季粉丝投票趋势, 可构建预测扩展, 时间序列预测: 基于 LSTM【9】模型, 对第 35 季及以后进行前瞻模拟; 输入历史投票模式与选手特征 (年龄、行业等随机森林重要性), 输出潜在冠军概率分布; 节目方可使用本模型的 policy_analysis 模块, 预评估新规则 (如增加现场观众投票权重) 对争议选手命运的影响。例如, 模拟显示“百分比法+评委救场制”综合得分最高 (4.80 分), 可作为未来季度推荐依据。

更广领域的潜在应用，粉丝经济分析：扩展至社交媒体，如 X 粉丝互动量预测，结合随机森林特征，量化名人“带货能力”或“争议价值”；选举与民意调查：在多候选人场景下，反向估算隐藏偏好分布，帮助分析“沉默多数”效应；企业决策：类比为多准则评价（如员工绩效=技术分+人气分），优化加权方案以平衡客观与主观因素。

七、参考文献

- [1] [Dancing with the Stars \(American TV series\) season 32 - Wikipedia](#)
- [2] Wikipedia. Dancing with the Stars (American TV series) [EB/OL]. [2024-05-20]. [https://en.wikipedia.org/wiki/Dancing_with_the_Stars_\(American_TV_series\)](https://en.wikipedia.org/wiki/Dancing_with_the_Stars_(American_TV_series)).
- [3] Cicchetti D V. Guidelines, criteria, and rules of thumb for evaluating normed and standardized assessment instruments in psychology[J]. Psychological Assessment, 1994, 6(4): 284-290.
- [4] Landis J R, Koch G G. The measurement of observer agreement for categorical data[J]. Biometrics, 1977, 33(1): 159-174.
- [5] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [6] 江苏卫视. 蒙面歌王(中国) [Z]. 2015. (引申参考: 维基百科. 蒙面歌王 (中国) [EB/OL]. [https://zh.wikipedia.org/zh-cn/蒙面歌王_\(中国\)](https://zh.wikipedia.org/zh-cn/蒙面歌王_(中国)))
- [7] Saltelli A, Ratto M, Andres T, et al. Global sensitivity analysis: the primer[M]. John Wiley & Sons, 2008.
- [8] Box G E P, Jenkins G M, Reinsel G C, et al. Time series analysis: forecasting and control[M]. John Wiley & Sons, 2015.
- [9] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.